Рабцевич Ксения Руслановна, ИУ5-62Б

Рубежный контроль №1

Тема: Технологии разведочного анализа и обработки данных.

Вариант 18. Номер задачи №3. Номер набора данных №2.

Задача №3. Для заданного набора данных произведите масштабирование данных (для одного признака) и преобразование категориальных признаков в количественные двумя способами (label encoding, one hot encoding) для одного признака.

Текстовое описание набора данных

В качестве набора данных мы будем использовать набор данных FiveThirtyEight Comic Characters Dataset (https://www.kaggle.com/fivethirtyeight/fivethirtyeight-comic-characters-dataset?select=dc-wikia-data.csv)

Набор данных содержит колонки:

- page_id - уникальный идентификатор страницы с персонажами в вики
- name - имя персанажа
- urlslug - уникальный URL-адрес вики, который приведет вас к персонажу
- ID - статус личности персонажа
- ALIGN - персонаж хороший, плохой или нейтральный
- EYE - цвет глаз персонажа
- HAIR - цвет волос персонажа
- SEX - пол персонажа (например, мужской, женский и т. д.)
- GSM - персонаж принадлежит к полу или сексуальному меньшинству (например, гомосексуальные персонажи, бисексуальные персонажи)
- ALIVE - персонаж жив или умер
- APPEARANCES - количество появлений персонажа в комиксах (по состоянию на 2 сентября 2014 г.)
- FIRST APPEARANCE - месяц и год первого появления персонажа в комиксе, если таковой имеется
- YEAR - год первого появления персонажа в комиксе, если таковой имеется

Импорт библиотек и загрузка данных

In [39]:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

In [40]:

```
data = pd.read_csv('dc-wikia.csv', sep=",")
```

Основные характеристики датасета

In [41]:

```
# Первые 5 строк датасета
data.head()
```

Out[41]:

	page_id	name	urlslug	ID	ALIGN	EYE	HAIR	
0	1422	Batman (Bruce Wayne)	\/wiki\/Batman_(Bruce_Wayne)	Secret Identity	Good Characters	Blue Eyes	Black Hair	Cha
1	23387	Superman (Clark Kent)	\/wiki\/Superman_(Clark_Kent)	Secret Identity	Good Characters	Blue Eyes	Black Hair	Cha
2	1458	Green Lantern (Hal Jordan)	\/wiki\/Green_Lantern_(Hal_Jordan)	Secret Identity	Good Characters	Brown Eyes	Brown Hair	Cha
3	1659	James Gordon (New Earth)	\/wiki\/James_Gordon_(New_Earth)	Public Identity	Good Characters	Brown Eyes	White Hair	Cha
4	1576	Richard Grayson (New Earth)	\/wiki\/Richard_Grayson_(New_Earth)	Secret Identity	Good Characters	Blue Eyes	Black Hair	Cha

In [42]:

```
# Размер датасета
data.shape
```

Out[42]:

```
(6896, 13)
```

B [43]:

```
# Список колонок с типами данных
data.dtypes
```

Out[43]:

```
page_id               int64
name                 object
urlslug              object
ID                   object
ALIGN                object
EYE                  object
HAIR                 object
SEX                  object
GSM                  object
ALIVE                object
APPEARANCES         float64
FIRST APPEARANCE     object
YEAR                float64
dtype: object
```

B [44]:

```
# Проверим наличие пустых значений
data.isnull().sum()
```

Out[44]:

```
page_id                0
name                   0
urlslug                0
ID                  2013
ALIGN                601
EYE                 3628
HAIR                2274
SEX                  125
GSM                 6832
ALIVE                  3
APPEARANCES          355
FIRST APPEARANCE      69
YEAR                  69
dtype: int64
```

B [45]:

```
# Основные статистические характеристки набора данных
data.describe()
```

Out[45]:

	page_id	APPEARANCES	YEAR
count	6896.000000	6541.000000	6827.000000
mean	147441.209252	23.625134	1989.766662
std	108388.631149	87.378509	16.824194
min	1380.000000	1.000000	1935.000000
25%	44105.500000	2.000000	1983.000000
50%	141267.000000	6.000000	1992.000000
75%	213203.000000	15.000000	2003.000000
max	404010.000000	3093.000000	2013.000000

Масштабирование данных (для одного признака)

B [46]:

```
# импорт
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

- MinMax масштабирование

B [47]:

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['YEAR']])
```

B [48]:

```
plt.hist(data['YEAR'], 50)
plt.show()
```

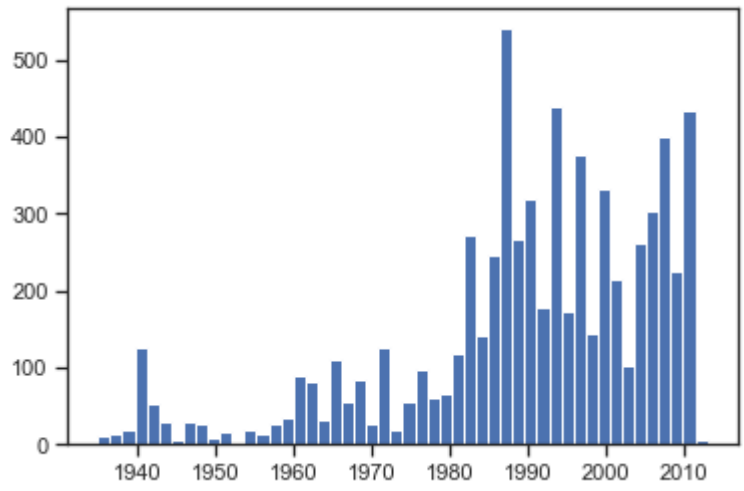

B [49]:

```
plt.hist(sc1_data, 50)
plt.show()
```

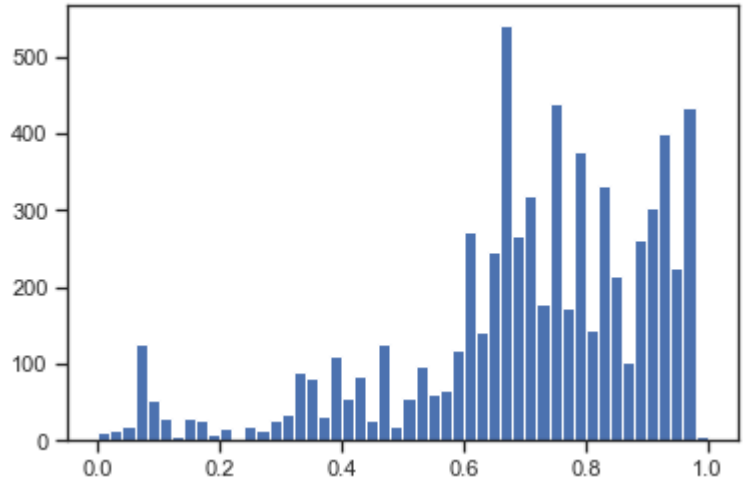

- Масштабирование данных на основе Z-оценки

B [50]:

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['YEAR']])
```

B [51]:

```
plt.hist(sc2_data, 50)
plt.show()
```

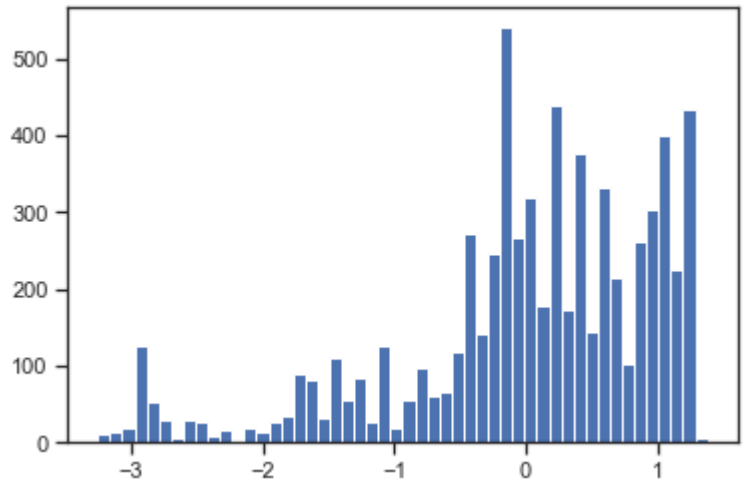

Преобразование категориальных признаков в количественные (label encoding, one hot encoding) для одного признака

B [52]:

```
cat_temp_data = data[['SEX']]
```

B [53]:

```
cat_temp_data['SEX'].unique()
```

Out[53]:

```
array(['Male Characters', 'Female Characters', nan,
       'Genderless Characters', 'Transgender Characters'], dtype=object)
```

B [54]:

```
#обработка пропусков
from sklearn.impute import SimpleImputer
```

B [55]:

```
# Импьютация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
np.unique(data_imp2)
```

Out[55]:

```
array(['Female Characters', 'Genderless Characters', 'Male Characters',
       'Transgender Characters'], dtype=object)
```

- label encoding

B [56]:

```
cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc
```

Out[56]:

	c1
0	Male Characters
1	Male Characters
2	Male Characters
3	Male Characters
4	Male Characters
...	...
6891	Female Characters
6892	Male Characters
6893	Male Characters
6894	Male Characters
6895	Male Characters

6896 rows × 1 columns

B [57]:

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

B [58]:

```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

B [59]:

```
np.unique(cat_enc_le)
```

Out[59]:

```
array([0, 1, 2, 3])
```

B [60]:

```
le.inverse_transform([ 0,  1,  2,  3])
```

Out[60]:

```
array(['Female Characters', 'Genderless Characters', 'Male Characters',
       'Transgender Characters'], dtype=object)
```

- one-hot encoding

B [61]:

```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
```

B [62]:

```
cat_enc.shape
```

Out[62]:

```
(6896, 1)
```

B [63]:

```
cat_enc_ohe.shape
```

Out[63]:

```
(6896, 4)
```

B [64]:

```
cat_enc_ohe.todense()[0:10]
```

Out[64]:

```
matrix([[0., 0., 1., 0.],
        [0., 0., 1., 0.],
        [0., 0., 1., 0.],
        [0., 0., 1., 0.],
        [0., 0., 1., 0.],
        [1., 0., 0., 0.],
        [0., 0., 1., 0.],
        [0., 0., 1., 0.],
        [1., 0., 0., 0.],
        [0., 0., 1., 0.]])
```

B [65]:

```
cat_enc.head(10)
```

Out[65]:

	c1
0	Male Characters
1	Male Characters
2	Male Characters
3	Male Characters
4	Male Characters
5	Female Characters
6	Male Characters
7	Male Characters
8	Female Characters
9	Male Characters

Гистограмма

Позволяет оценить плотность вероятности распределения данных.

B [66]:

```
fig, ax = plt.subplots(figsize=(5,5))
sns.distplot(data['YEAR'])
```

```
C:\Users\kenia\anaconda3\lib\site-packages\seaborn\distributions.py:2551: Fu
tureWarning: `distplot` is a deprecated function and will be removed in a fu
ture version. Please adapt your code to use either `displot` (a figure-level
function with similar flexibility) or `histplot` (an axes-level function for
histograms).
  warnings.warn(msg, FutureWarning)
```

Out[66]:

```
<AxesSubplot:xlabel='YEAR', ylabel='Density'>
```