Министерство образования и науки Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего профессионального образования
«Московский государственный технический университет имени Н.Э. Баумана»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ	**«Информатики и систем управления»**
КАФЕДРА	Системы обработки информации и управления

Дисциплина «Технологии машинного обучения»

РУБЕЖНЫЙ КОНТРОЛЬ №2
«Методы построения моделей машинного обучения»
Вариант 18

Студент	Рабцевич К. Р. ИУ5-62Б
Преподаватель	Гапанюк Ю. Е.

1. Задание

Группа	Метод №1	Метод №2
ИУ5-62Б	Метод опорных векторов	Случайный лес

Задание.

Для заданного набора данных постройте модели классификации или регрессии. Для построения моделей используйте методы 1 и 2. Оцените качество моделей на основе подходящих метрик качества. Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Наборы данных:

https://www.kaggle.com/kmldas/loan-default-prediction

2. Выполнение задания

Просмотрим данные. Датасет содержит индекс (который можно не использовать в дальнейшем, т.к. он уникальный и повторяет встроенные индексы в пандасе); два бинарных значения – устроен ли человек на работу и таргет, обозначающий, что человек не платит; два числовых значения – банковский счет и ежегодный доход.

```
[ ]  data = pd.read_csv('Default_Fin.csv')
     data.head()
```

	Index	Employed	Bank Balance	Annual Salary	Defaulted?
0	1	1	8754.36	532339.56	0
1	2	0	9806.16	145273.56	0
2	3	1	12882.60	381205.68	0
3	4	1	6351.00	428453.88	0
4	5	1	9427.92	461562.00	0

```
[ ]  data.shape
```

```
(10000, 5)
```

```
[ ]  data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10000 entries, 0 to 9999
Data columns (total 5 columns):
 #   Column         Non-Null Count  Dtype  
---  ------         --------------  -----  
 0   Index          10000 non-null  int64  
 1   Employed       10000 non-null  int64  
 2   Bank Balance   10000 non-null  float64
 3   Annual Salary  10000 non-null  float64
 4   Defaulted?     10000 non-null  int64  
dtypes: float64(2), int64(3)
memory usage: 390.8 KB
```

Проверим, содержат ли колонки нулевые значения:

```
[ ]  data.isnull().sum()
```

```
Index            0
Employed         0
Bank Balance     0
Annual Salary    0
Defaulted?       0
dtype: int64
```

Данные полностью заполнены. Теперь нужно нормализовать их:

```
[ ]  from sklearn.preprocessing import StandardScaler

     scaler = StandardScaler()
     X_scaled = scaler.fit_transform(X)
```

```
[ ]  X_scaled_col_1 = scaler.fit_transform(X[['Bank Balance']])
     X_scaled_col_2 = scaler.fit_transform(X[['Annual Salary']])
```

```
[ ]  sns.histplot(X['Bank Balance']);
```

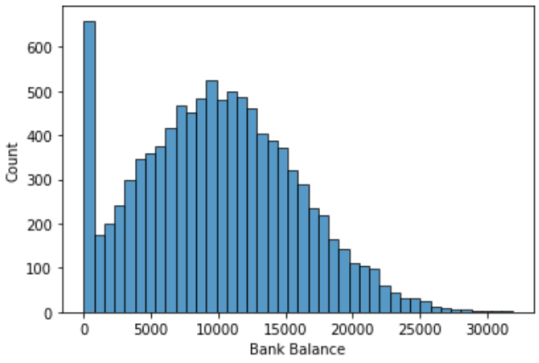


```
[ ]  sns.histplot(X_scaled_col_1);
```

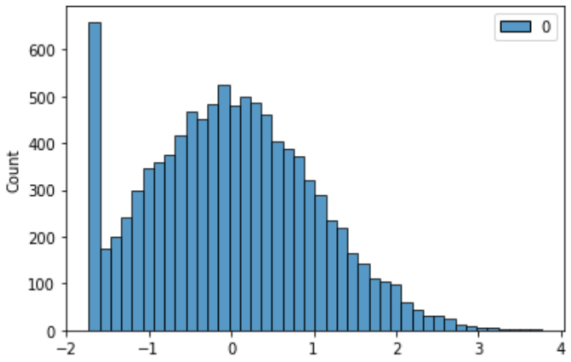


```
[ ]  sns.histplot(X['Annual Salary']);
```

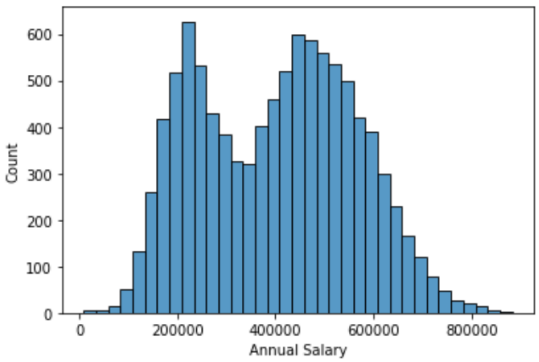


```
[ ]  sns.histplot(X_scaled_col_2);
```

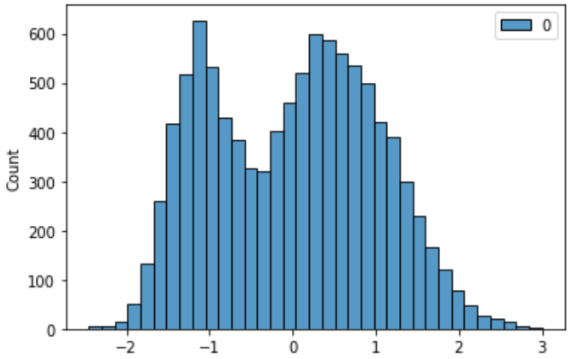

StandartScaler масштабирует данные таким образом, что среднее значение равно 0, а стандартное отклонение – 1.

Теперь разделим датасет на тренировочную и тестовую выборку в отношении 80% к 20%.

```
[ ]  X = data[feature_cols]
     y = data['Defaulted?']
```

```
[ ]  from sklearn.model_selection import train_test_split

     X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size = 0.2, random_state=42)
```

Задача – определить, по имеющимся данным, выполнит ли человек свою часть договора по займу.

Метод опорных векторов:

```
[ ]  from sklearn.svm import SVC

     svc = SVC()
     svc.fit(X_train, y_train)
```

```
SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0,
    decision_function_shape='ovr', degree=3, gamma='scale', kernel='rbf',
    max_iter=-1, probability=False, random_state=None, shrinking=True,
    tol=0.001, verbose=False)
```

```
[ ]  y_pred_svc = svc.predict(X_test)
```

```
[ ]  print('Accuracy Score: {}\nF1 Score: {}'.format(
         accuracy_score(y_test, y_pred_svc),
         f1_score(y_test, y_pred_svc)))
```

```
Accuracy Score: 0.968
F1 Score: 0.2558139534883721
```

Случайный лес:

```
[ ]  from sklearn.ensemble import RandomForestClassifier

     rf = RandomForestClassifier(n_estimators=4)
     rf.fit(X_train, y_train)
```

```
RandomForestClassifier(bootstrap=True, ccp_alpha=0.0, class_weight=None,
                       criterion='gini', max_depth=None, max_features='auto',
                       max_leaf_nodes=None, max_samples=None,
                       min_impurity_decrease=0.0, min_impurity_split=None,
                       min_samples_leaf=1, min_samples_split=2,
                       min_weight_fraction_leaf=0.0, n_estimators=4,
                       n_jobs=None, oob_score=False, random_state=None,
                       verbose=0, warm_start=False)
```

```
[ ]  y_pred_rf = rf.predict(X_test)
```

```
[ ]  print('Accuracy Score: {}\nF1 Score: {}'.format(
         accuracy_score(y_test, y_pred_rf),
         f1_score(y_test, y_pred_rf)))
```

```
Accuracy Score: 0.9645
F1 Score: 0.297029702970297
```

Были использованы такие метрики, как Accuracy Score (подсчитывает, как часто предсказание равняется действительному значению) и F1 Score

(принимает значение от 0 до 1, поддерживает баланс между precision и recall – если точность или recall низкие, то и F1 низкая).

```
Accuracy = (TP+TN)/(TP+FP+FN+TN)
```

$$F_1 = 2 * \frac{precision * recall}{precision + recall}$$

В итоге, метод опорных векторов, обучился лучше, чем модель случайного леса.