Лабораторная работа №2

Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных.

Цель лабораторной работы: изучение способов предварительной обработки данных для дальнейшего формирования моделей.

Задание:

1. Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.)
2. Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи:
   - обработку пропусков в данных;
   - кодирование категориальных признаков;
   - масштабирование данных.

Импорт библиотек

In [9]:

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Загрузка и первичный анализ данных

Используем данные с kaggle Фильмы и телешоу Netflix (https://www.kaggle.com/shivamb/netflix-shows)

In [10]:

```
data = pd.read_csv('data/netflix_titles.csv', sep=",")
```

In [11]:

```
# размер набора данных
data.shape
```

Out[11]:

```
(7787, 12)
```

В [12]:

```
# типы колонок
data.dtypes
```

Out[12]:

```
show_id         object
type            object
title           object
director        object
cast            object
country         object
date_added      object
release_year     int64
rating          object
duration        object
listed_in       object
description     object
dtype: object
```

В [13]:

```
# проверим есть ли пропущенные значения
data.isnull().sum()
```

Out[13]:

```
show_id            0
type               0
title              0
director        2389
cast             718
country          507
date_added        10
release_year       0
rating             7
duration           0
listed_in          0
description        0
dtype: int64
```

In [14]:

```
# Первые 5 строк датасета
data.head()
```

Out[14]:

	show_id	type	title	director	cast	country	date_added	release_year	rating	du
0	s1	TV Show	3%	NaN	João Miguel, Bianca Comparato, Michel Gomes, R...	Brazil	August 14, 2020	2020	TV-MA	Se
1	s2	Movie	7:19	Jorge Michel Grau	Demián Bichir, Héctor Bonilla, Oscar Serrano, ...	Mexico	December 23, 2016	2016	TV-MA	9
2	s3	Movie	23:59	Gilbert Chan	Tedd Chan, Stella Chung, Henley Hii, Lawrence ...	Singapore	December 20, 2018	2011	R	7
3	s4	Movie	9	Shane Acker	Elijah Wood, John C. Reilly, Jennifer Connelly...	United States	November 16, 2017	2009	PG-13	8
4	s5	Movie	21	Robert Luketic	Jim Sturgess, Kevin Spacey, Kate Bosworth, Aar...	United States	January 1, 2020	2008	PG-13	12

In [15]:

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 7787
```

Обработка пропусков в данных

В [16]:

```
# Выберем колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0:
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col,
```

```
Колонка director. Тип данных object. Количество пустых значений 2389, 30.6
8%.
Колонка cast. Тип данных object. Количество пустых значений 718, 9.22%.
Колонка country. Тип данных object. Количество пустых значений 507, 6.51%.
Колонка date_added. Тип данных object. Количество пустых значений 10, 0.13%.
Колонка rating. Тип данных object. Количество пустых значений 7, 0.09%.
```

В [17]:

```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```

Out[17]:

	director	cast	country	date_added	rating
0	NaN	João Miguel, Bianca Comparato, Michel Gomes, R...	Brazil	August 14, 2020	TV-MA
1	Jorge Michel Grau	Demián Bichir, Héctor Bonilla, Oscar Serrano, ...	Mexico	December 23, 2016	TV-MA
2	Gilbert Chan	Tedd Chan, Stella Chung, Henley Hii, Lawrence ...	Singapore	December 20, 2018	R
3	Shane Acker	Elijah Wood, John C. Reilly, Jennifer Connelly...	United States	November 16, 2017	PG-13
4	Robert Luketic	Jim Sturgess, Kevin Spacey, Kate Bosworth, Aar...	United States	January 1, 2020	PG-13
...	...	...	...	...	...
7782	Josef Fares	Imad Creidi, Antoinette Turk, Elias Gergi, Car...	Sweden, Czech Republic, United Kingdom, Denmar...	October 19, 2020	TV-MA
7783	Mozez Singh	Vicky Kaushal, Sarah-Jane Dias, Raaghav Chanan...	India	March 2, 2019	TV-14
7784	NaN	Nasty C	NaN	September 25, 2020	TV-MA
7785	NaN	Adriano Zumbo, Rachel Khoo	Australia	October 31, 2020	TV-PG
7786	Sam Dunn	NaN	United Kingdom, Canada, United States	March 1, 2020	TV-MA

7787 rows × 5 columns

В [18]:

```
cat_temp_data = data[['rating']]
cat_temp_data.head()
```

Out[18]:

	rating
0	TV-MA
1	TV-MA
2	R
3	PG-13
4	PG-13

В [19]:

```
cat_temp_data['rating'].unique()
```

Out[19]:

```
array(['TV-MA', 'R', 'PG-13', 'TV-14', 'TV-PG', 'NR', 'TV-G', 'TV-Y', nan,
       'TV-Y7', 'PG', 'G', 'NC-17', 'TV-Y7-FV', 'UR'], dtype=object)
```

В [20]:

```
cat_temp_data[cat_temp_data['rating'].isnull()].shape
```

Out[20]:

```
(7, 1)
```

Подключим библиотеки для обработки пропусков

В [21]:

```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

В [22]:

```
# Импьютация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

Out[22]:

```
array([['TV-MA'],
       ['TV-MA'],
       ['R'],
       ...,
       ['TV-MA'],
       ['TV-PG'],
       ['TV-MA']], dtype=object)
```

В [23]:

```
# Пустые значения отсутствуют
np.unique(data_imp2)
```

Out[23]:

```
array(['G', 'NC-17', 'NR', 'PG', 'PG-13', 'R', 'TV-14', 'TV-G', 'TV-MA',
       'TV-PG', 'TV-Y', 'TV-Y7', 'TV-Y7-FV', 'UR'], dtype=object)
```

В [24]:

```
# Импьютация константой
imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='NA')
data_imp3 = imp3.fit_transform(cat_temp_data)
data_imp3
```

Out[24]:

```
array([['TV-MA'],
       ['TV-MA'],
       ['R'],
       ...,
       ['TV-MA'],
       ['TV-PG'],
       ['TV-MA']], dtype=object)
```

В [25]:

```
np.unique(data_imp3)
```

Out[25]:

```
array(['G', 'NA', 'NC-17', 'NR', 'PG', 'PG-13', 'R', 'TV-14', 'TV-G',
       'TV-MA', 'TV-PG', 'TV-Y', 'TV-Y7', 'TV-Y7-FV', 'UR'], dtype=object)
```

В [26]:

```
data_imp3[data_imp3=='NA'].size
```

Out[26]:

```
7
```

Кодирование категориальных признаков

Кодирование категорий целочисленными значениями - label encoding (https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.LabelEncoder.html)

B [27]:

```
cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc
```

Out[27]:

	c1
0	TV-MA
1	TV-MA
2	R
3	PG-13
4	PG-13
...	...
7782	TV-MA
7783	TV-14
7784	TV-MA
7785	TV-PG
7786	TV-MA

7787 rows × 1 columns

B [28]:

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

B [29]:

```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

B [30]:

```
np.unique(cat_enc_le)
```

Out[30]:

```
array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13])
```

B [31]:

```
le.inverse_transform([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13])
```

Out[31]:

```
array(['G', 'NC-17', 'NR', 'PG', 'PG-13', 'R', 'TV-14', 'TV-G', 'TV-MA',
       'TV-PG', 'TV-Y', 'TV-Y7', 'TV-Y7-FV', 'UR'], dtype=object)
```

Кодирование категорий наборами бинарных значений - one-hot encoding (https://scikit-

learn.org/stable/modules/generated/sklearn.preprocessing.OneHotEncoder.html)

B [32]:

```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])
```

B [33]:

```
cat_enc.shape
```

Out[33]:

```
(7787, 1)
```

B [34]:

```
cat_enc_ohe.shape
```

Out[34]:

```
(7787, 14)
```

B [35]:

```
cat_enc_ohe.todense()[0:10]
```

Out[35]:

```
matrix([[0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0., 0., 0.],
        [0., 0., 0., 0., 0., 0., 0., 0., 1., 0., 0., 0., 0., 0.]])
```

B [36]:

```
cat_enc.head(10)
```

Out[36]:

	c1
0	TV-MA
1	TV-MA
2	R
3	PG-13
4	PG-13
5	TV-MA
6	TV-MA
7	R
8	TV-14
9	TV-MA

Масштабирование данных

B [37]:

```
from sklearn.preprocessing import MinMaxScaler, StandardScaler, Normalizer
```

MinMax масштабирование (https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.MinMaxScaler.html)

B [38]:

```
sc1 = MinMaxScaler()
sc1_data = sc1.fit_transform(data[['release_year']])
```

B [39]:

```
plt.hist(data['release_year'], 100)
plt.show()
```

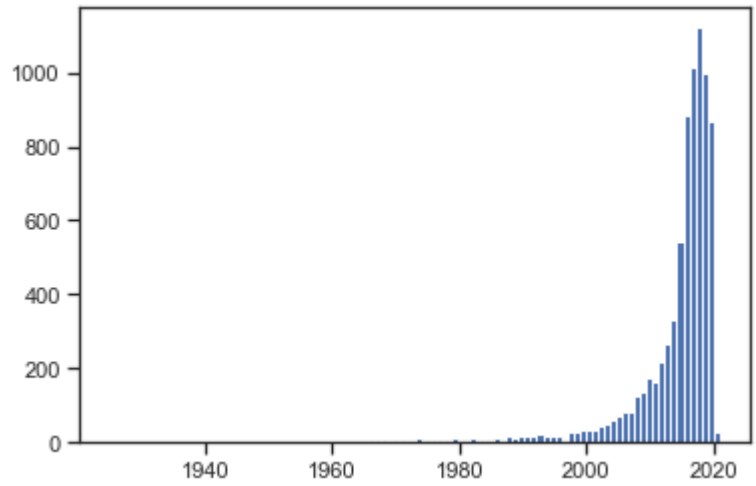

B [40]:

```
plt.hist(sc1_data, 100)
plt.show()
```

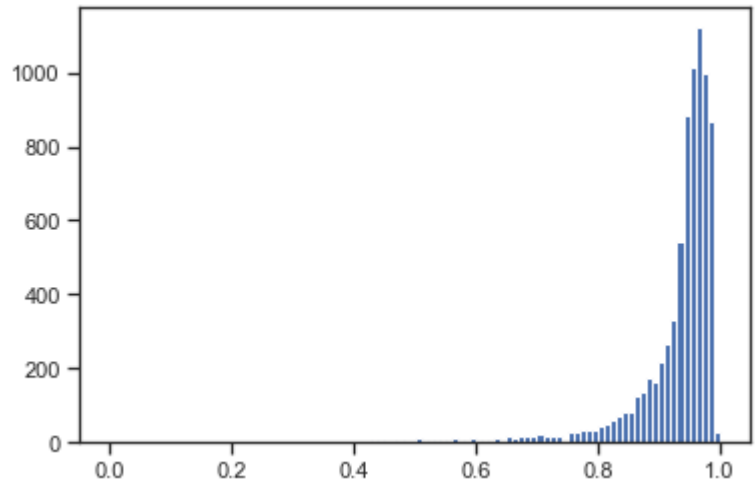

Масштабирование данных на основе Z-оценки (https://ru.wikipedia.org/wiki/Z-%D0%BE%D1%86%D0%B5%D0%BD%D0%BA%D0%B0) - StandardScaler (https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html#s

B [41]:

```
sc2 = StandardScaler()
sc2_data = sc2.fit_transform(data[['release_year']])
```

B [42]:

```
plt.hist(sc2_data, 100)
plt.show()
```