Цель лабораторной работы: изучение линейных моделей, SVM и деревьев решений.

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
 - о одну из линейных моделей;
 - o SVM;
 - о дерево решений.
- 5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

Дополнительные задания:

- Проведите эксперименты с важностью признаков в дереве решений.
- Визуализируйте дерево решений.

Линейные модели, **SVM** и деревья решений.

В качестве набора данных используется набор данных по раку груди висконсин (диагностический) Файл содержит следующие колонки:

- радиус (среднее расстояние от центра до точек по периметру)
- текстура (стандартное отклонение значений шкалы серого)
- периметр
- область
- гладкость (локальное изменение длины радиуса)
- компактность (периметр ^ 2 / площадь 1.0)
- вогнутость (выраженность вогнутых участков контура)
- вогнутые точки (количество вогнутых участков контура)
- симметрия
- фрактальная размерность («приближение береговой линии» 1)

Классы:

- **WDBC-**злокачественный
- WDBC-доброкачественный

In [215]:

```
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from scipy import stats
from sklearn.datasets import load breast cancer
from sklearn.model selection import train test split
from sklearn.linear model import LogisticRegression
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score, classification_repor
from sklearn.metrics import confusion matrix
from sklearn.metrics import mean absolute error, mean squared error, mean squared log err
or, median absolute error, r2 score
from sklearn.metrics import roc curve, roc auc score
from sklearn.linear model import LinearRegression
from sklearn.linear model import SGDRegressor
from sklearn.linear_model import SGDClassifier
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export graphviz
import seaborn as sns
import matplotlib.pyplot as plt
import graphviz
import pydotplus
%matplotlib inline
sns.set(style="ticks")
```

```
In [8]:
```

```
breast = load_breast_cancer()
```

```
In [9]:
```

```
df_breast = pd.DataFrame(breast.data,columns=breast.feature_names)
df_breast['target'] = pd.Series(breast.target)
df_breast.head()
```

Out[9]:

	IUUIUU	WALLI	pormotor	ui vu		Julipada ida	volloutity	points mean	oyou y	dimension mean			P~
0	radios	texture	peril neter	1001eg	smoothness	compactness	concavity	COMERYS points	symmetry	0 ^f ractal dimension	:::	texture	perih
+	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	0.05667		23.41	
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	0.05999		25.53	18
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	0.09744		26.50	•
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	0.05883		16.67	15

5 rows × 31 columns

1

In [12]:

```
# Значения и наименования значений целевого признака list(zip(np.unique(breast.target), breast.target_names))
```

Out[12]:

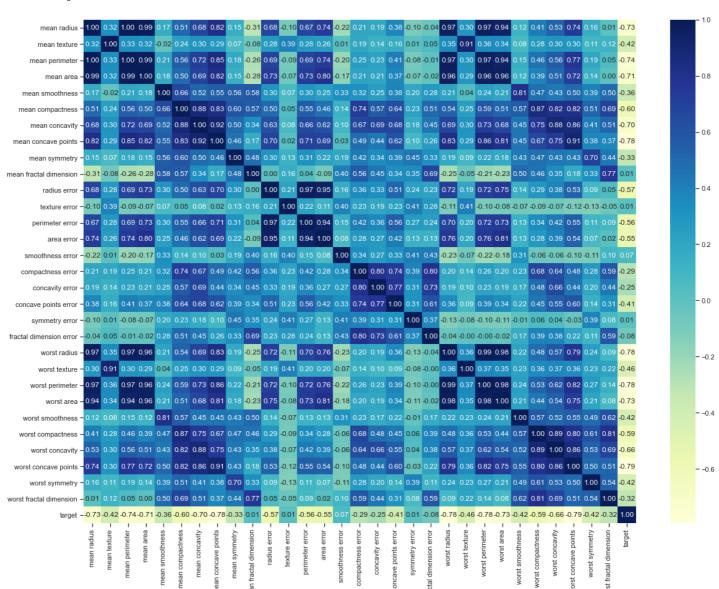
```
[(0, 'malignant'), (1, 'benign')]
```

In [206]:

```
#Построим корреляционную матрицу
fig, ax = plt.subplots(figsize=(20,15))
sns.heatmap(df_breast.corr(method='pearson'), ax=ax, annot=True, fmt='.2f', cmap="YlGnBu")
```

Out[206]:

<AxesSubplot:>



Логистическая регрессия (LogisticRegression)

```
In [19]:
breast X train, breast X test, breast y train, breast y test = train test split(
    breast.data, breast.target, test size=0.5, random state=1)
In [34]:
cl1 = LogisticRegression(max iter=10000)
In [35]:
cl1.fit(breast X train, breast y train)
Out[35]:
LogisticRegression (max iter=10000)
In [24]:
pred breast y test = cl1.predict(breast X test)
pred breast y test
Out[24]:
array([1, 0, 1, 0, 0, 0, 0, 0, 1, 1, 1, 0, 0, 1, 1, 1, 1, 1, 1, 1, 0, 1, 1,
       0, 1, 0, 1, 1, 0, 0, 0, 0, 1, 0, 0, 1, 1, 0, 1, 0, 1, 1, 1, 1, 1,
       1, 0, 1, 1, 1, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 0, 1, 1,
       1, 0, 1, 1, 1, 1, 0, 0, 1, 0, 1, 1, 1, 0, 1, 0, 1, 0, 1, 1, 1, 1,
       0, 1, 1, 0, 1, 1, 0, 0, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0,
       0, 1, 0, 1, 0, 0, 1, 1, 1, 1, 1, 0, 0, 1, 1, 0, 0, 0, 0, 0, 1, 1,
       1, 0, 1, 0, 0, 1, 1, 1, 0, 0, 1, 0, 1, 0, 1, 1, 1, 0, 1, 1, 0, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 0, 1, 1, 1, 0, 0, 0, 1, 1, 1, 1, 0, 1, 1,
       1, 1, 1, 1, 1, 1, 1, 1, 1, 0, 0, 1, 0, 1, 1, 1, 0, 0, 0, 1, 1, 0,
       0, 1, 1, 1, 1, 0, 0, 1, 1, 1, 0, 0, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1,
       1, 1, 0, 1, 0, 1, 1, 0, 0, 1, 0, 1, 0, 0, 0, 1, 0, 0, 1, 1, 1, 1,
          1, 1, 1, 1, 1, 0, 0, 0, 1, 0, 1, 1, 0, 1, 0, 1, 1, 1, 1, 1, 0,
       1, 1, 0, 1, 1, 1, 1, 0, 1, 1, 0, 1, 1, 1, 1, 0, 1, 1, 1, 1, 1])
In [25]:
pred breast y test proba = cll.predict proba(breast X test)
pred breast y test proba[:10]
Out[25]:
array([[1.49258350e-01, 8.50741650e-01],
       [8.53428519e-01, 1.46571481e-01],
       [6.17810193e-05, 9.99938219e-01],
       [9.99911960e-01, 8.80397272e-05],
       [5.52972743e-01, 4.47027257e-01],
       [9.99953966e-01, 4.60336276e-05],
       [9.99839687e-01, 1.60312607e-04],
       [5.85687939e-01, 4.14312061e-01],
       [7.51937022e-03, 9.92480630e-01],
       [5.46643320e-04, 9.99453357e-01]])
In [26]:
# Вероятность принадлежности к 0 классу
[round(x, 4) for x in pred breast y test proba[:10,0]]
Out[26]:
[0.1493, 0.8534, 0.0001, 0.9999, 0.553, 1.0, 0.9998, 0.5857, 0.0075, 0.0005]
In [27]:
# Вероятность принадлежности к 1 классу
[round(x, 4) for x in pred breast y test proba[:10,1]]
```

```
Out [27]:
[0.8507, 0.1466, 0.9999, 0.0001, 0.447, 0.0, 0.0002, 0.4143, 0.9925, 0.9995]
In [28]:
# Сумма вероятностей равна 1
pred breast y test proba[:10,0] + pred breast y test proba[:10,1]
Out[28]:
array([1., 1., 1., 1., 1., 1., 1., 1., 1.])
In [29]:
accuracy score (breast y test, pred breast y test)
Out[29]:
0.9052631578947369
In [30]:
def accuracy score for classes (
    y true: np.ndarray,
    y pred: np.ndarray) -> Dict[int, float]:
    Вычисление метрики accuracy для каждого класса
    y true - истинные значения классов
    y pred - предсказанные значения классов
    Возвращает словарь: ключ - метка класса,
    значение - Accuracy для данного класса
    # Для удобства фильтрации сформируем Pandas DataFrame
    d = { 't': y true, 'p': y pred}
    df = pd.DataFrame(data=d)
    # Метки классов
    classes = np.unique(y true)
    # Результирующий словарь
    res = dict()
    # Перебор меток классов
    for c in classes:
        # отфильтруем данные, которые соответствуют
        # текущей метке класса в истинных значениях
        temp data flt = df[df['t']==c]
        # расчет ассиracy для заданной метки класса
        temp acc = accuracy score(
            temp data flt['t'].values,
            temp_data_flt['p'].values)
        # сохранение результата в словарь
        res[c] = temp acc
    return res
def print accuracy score for classes (
    y_true: np.ndarray,
    y_pred: np.ndarray):
    Вывод метрики accuracy для каждого класса
    accs = accuracy score for classes(y true, y pred)
    if len(accs)>0:
       print('Метка \t Accuracy')
    for i in accs:
        print('{} \t {}'.format(i, accs[i]))
In [31]:
print_accuracy_score_for_classes(breast_y_test, pred_breast_y_test)
```

Метка

0

1

Accuracy

0.8446601941747572

0.9395604395604396

Метод опорных векторов (SVC)

```
In [102]:
breast_X_a = df_breast['worst radius'].values
breast_X_b = df_breast['worst texture'].values
breast_X = np.column_stack((breast_X_a, breast_X_b))
breast_y = breast.target

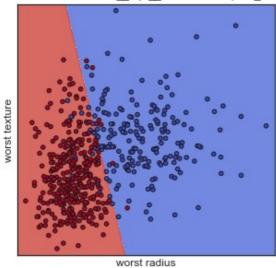
In [104]:

def make_meshgrid(x, y, h=.02):
    """Create a mesh of points to plot in
```

```
"""Create a mesh of points to plot in
   Parameters
    _____
   x: data to base x-axis meshgrid on
   y: data to base y-axis meshgrid on
   h: stepsize for meshgrid, optional
   Returns
   xx, yy : ndarray
   x \min, x \max = x.\min() - 1, x.\max() + 1
   y \min, y \max = y.\min() - 1, y.\max() + 1
   xx, yy = np.meshgrid(np.arange(x min, x max, h),
                         np.arange(y_min, y_max, h))
   return xx, yy
def plot contours(ax, clf, xx, yy, **params):
    """Plot the decision boundaries for a classifier.
   Parameters
    _____
   ax: matplotlib axes object
   clf: a classifier
   xx: meshgrid ndarray
   yy: meshgrid ndarray
   params: dictionary of params to pass to contourf, optional
   Z = clf.predict(np.c [xx.ravel(), yy.ravel()])
   Z = Z.reshape(xx.shape)
   #Можно проверить все ли метки классов предсказываются
   #print(np.unique(Z))
   out = ax.contourf(xx, yy, Z, **params)
   return out
def plot cl(clf):
   title = clf. repr
   clf.fit(breast_X, breast_y)
   fig, ax = plt.subplots(figsize=(5,5))
   X0, X1 = breast X[:, 0], breast X[:, 1]
   xx, yy = make meshgrid(X0, X1)
   plot contours(ax, clf, xx, yy, cmap=plt.cm.coolwarm, alpha=0.8)
   ax.scatter(X0, X1, c=breast y, cmap=plt.cm.coolwarm, s=20, edgecolors='k')
   ax.set xlim(xx.min(), xx.max())
   ax.set ylim(yy.min(), yy.max())
   ax.set xlabel('worst radius')
   ax.set ylabel('worst texture')
   ax.set xticks(())
   ax.set yticks(())
   ax.set title(title)
   plt.show()
```

```
In [105]:
plot_cl(LinearSVC(C=1.0, max_iter=100000))
```

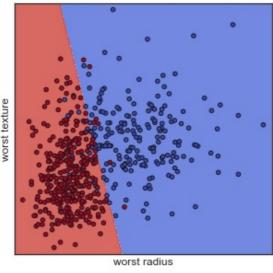
<bound method BaseEstimator.__repr__ of LinearSVC(max_iter=100000)>



In [106]:

```
plot_cl(LinearSVC(C=1.0, penalty='11', dual=False, max_iter=10000))
```

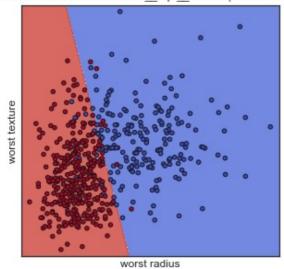
<bound method BaseEstimator.__repr__ of LinearSVC(dual=False, max_iter=10000, penalty='11')>



In [107]:

```
plot_cl(SVC(kernel='linear', C=1.0))
```

<bound method BaseEstimator.__repr__ of SVC(kernel='linear')>



In [108]:

```
plot_cl(SVC(kernel='rbf', gamma=0.2, C=1.0))
```

shound method DescEntimeter sons of OV/O/semme=0.0\%

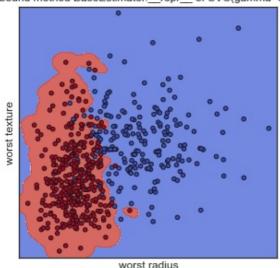
Spourid method basecsumator._ _repr__ or 5vc(gamma=v.z)> worst texture

In [109]:

```
plot_cl(SVC(kernel='rbf', gamma=0.9, C=1.0))
```

<bound method BaseEstimator.__repr__ of SVC(gamma=0.9)>

worst radius

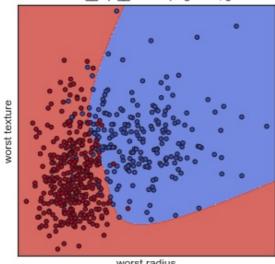


worst radius

In [110]:

```
plot_cl(SVC(kernel='poly', degree=4, gamma=0.2, C=1.0))
```

<bound method BaseEstimator.__repr__ of SVC(degree=4, gamma=0.2, kernel='poly')>

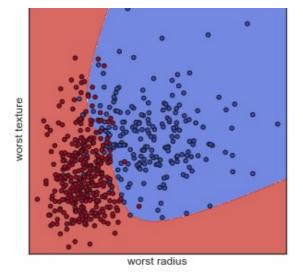


worst radius

In [111]:

```
plot_cl(SVC(kernel='poly', degree=4, gamma=0.9, C=1.0))
```

<bound method BaseEstimator.__repr__ of SVC(degree=4, gamma=0.9, kernel='poly')>



In [135]:

Out[135]:

```
((284, 30), (285, 30))
```

In [192]:

```
svc_1 = SVC()
svc_1.fit(breast_X_train_1, breast_y_train_1)
```

Out[192]:

SVC()

In [193]:

```
breast y pred 1 = svc 1.predict(breast X test 1)
```

In [194]:

```
\label{lem:mean_absolute_error(breast_y_test_1, breast_y_pred_1), mean_squared_error(breast_y_test_1, breast_y_pred_1), mean_squared_error(breast_y_test_1, breast_y_pred_1)
```

Out[194]:

(0.0912280701754386, 0.0912280701754386)

Деревья решений (DecisionTreeClassifier)

In [120]:

```
breast_x_ds = pd.DataFrame(data=breast['data'], columns=breast['feature_names'])
breast_x_ds.head()
```

Out[120]:

	mean radius	mean texture	mean perimeter	mean area	mean smoothness	mean compactness	mean concavity	mean concave points	mean symmetry	mean fractal dimension	 worst radius	wors textur
0	17.99	10.38	122.80	1001.0	0.11840	0.27760	0.3001	0.14710	0.2419	0.07871	 25.38	17.3
1	20.57	17.77	132.90	1326.0	0.08474	0.07864	0.0869	0.07017	0.1812	0.05667	 24.99	23.4
2	19.69	21.25	130.00	1203.0	0.10960	0.15990	0.1974	0.12790	0.2069	0.05999	 23.57	25.5
3	11.42	20.38	77.58	386.1	0.14250	0.28390	0.2414	0.10520	0.2597	0.09744	 14.91	26.5
4	20.29	14.34	135.10	1297.0	0.10030	0.13280	0.1980	0.10430	0.1809	0.05883	 22.54	16.6

```
5 rows × 30 columns
In [202]:
# Обучим дерево на всех признаках
breast tree cl = DecisionTreeClassifier(random state=1)
breast_tree_cl.fit(breast_x_ds, breast.target)
breast tree cl
Out[202]:
DecisionTreeClassifier(random state=1)
In [122]:
from IPython.core.display import HTML
from sklearn.tree.export import export text
tree rules = export text(breast tree cl, feature names=list(breast x ds.columns))
HTML('' + tree_rules + '')
C:\ProgramData\Anaconda3\lib\site-packages\sklearn\utils\deprecation.py:143: FutureWarnin
g: The sklearn.tree.export module is deprecated in version 0.22 and will be removed in v
ersion 0.24. The corresponding classes / functions should instead be imported from sklear
n.tree. Anything that cannot be imported from sklearn.tree is now part of the private API
 warnings.warn(message, FutureWarning)
Out[122]:
|--- worst radius <= 16.80
    |--- worst concave points <= 0.14
        |--- worst symmetry <= 0.16
           |--- class: 0
        |--- worst symmetry > 0.16
           |--- area error <= 38.60
                |--- smoothness error <= 0.00
                    |--- fractal dimension error <= 0.00
                       |--- class: 0
                    |--- fractal dimension error > 0.00
                    | |--- class: 1
                |--- smoothness error > 0.00
                    |--- worst texture <= 33.27
                      |--- class: 1
                    |--- worst texture > 33.27
                       |--- worst texture <= 33.56
                           |--- class: 0
                       |--- worst texture > 33.56
                       | |--- class: 1
            |--- area error > 38.60
                |--- symmetry error <= 0.02
                   |--- class: 0
                |--- symmetry error > 0.02
                    |--- area error <= 39.15
                    | |--- class: 0
                    |--- area error > 39.15
                    | |--- class: 1
     --- worst concave points > 0.14
        |--- worst texture <= 25.67
```

|--- worst area <= 810.30

|--- class: 1

|--- mean smoothness <= 0.12

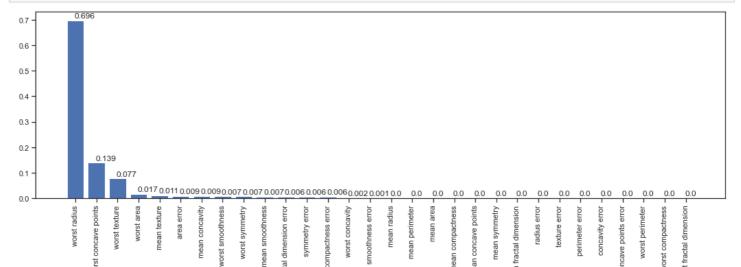
|--- mean smoothness > 0.12

```
|--- worst area <= 844.65
                   |--- class: 0
                |--- worst area > 844.65
                    |--- class: 1
        |--- worst texture > 25.67
            |--- mean concavity <= 0.10
                |--- mean texture <= 19.44
                   |--- class: 1
               |--- mean texture > 19.44
                | |--- class: 0
            |--- mean concavity > 0.10
            |--- class: 0
   - worst radius > 16.80
    |--- worst texture <= 19.91
        |--- worst concave points <= 0.15
           |--- class: 1
        |--- worst concave points > 0.15
           |--- class: 0
    |--- worst texture > 19.91
        |--- worst smoothness <= 0.09
           |--- class: 1
        |--- worst smoothness > 0.09
           |--- worst concavity <= 0.18
               |--- compactness error <= 0.02
                |--- class: 0
               |--- compactness error > 0.02
               | |--- class: 1
            |--- worst concavity > 0.18
            | |--- class: 0
In [222]:
dot data = export graphviz(breast tree cl, out file=None,
                           feature names=breast.feature names,
                           class names=breast.target names,
                           filled=True, rounded=True, special characters=True)
graph = graphviz.Source(dot data)
graph
Out[222]:
In [124]:
# Важность признаков
list(zip(breast x ds.columns.values, breast tree cl.feature importances ))
Out[124]:
[('mean radius', 0.0),
 ('mean texture', 0.011277152370382112),
 ('mean perimeter', 0.0),
 ('mean area', 0.0),
 ('mean smoothness', 0.007016894808237761),
 ('mean compactness', 0.0),
 ('mean concavity', 0.008771118510297198),
 ('mean concave points', 0.0),
 ('mean symmetry', 0.0),
 ('mean fractal dimension', 0.0),
 ('radius error', 0.0),
 ('texture error', 0.0),
 ('perimeter error', 0.0),
 ('area error', 0.008936807857691388),
 ('smoothness error', 0.0010038401246787545),
 ('compactness error', 0.005638576185191056),
```

```
('symmetry error', 0.005831348020582203),
 ('fractal dimension error', 0.00644408706878978),
 ('worst radius', 0.6955935182252058),
 ('worst texture', 0.07728413233375948),
 ('worst perimeter', 0.0),
 ('worst area', 0.016724478603093007),
 ('worst smoothness', 0.007387982534891388),
 ('worst compactness', 0.0),
 ('worst concavity', 0.0018358155021552392),
 ('worst concave points', 0.1389382501669036),
 ('worst symmetry', 0.007315997688141106),
 ('worst fractal dimension', 0.0)]
In [126]:
# Важность признаков в сумме дает почти единицу
sum(breast tree cl.feature importances )
Out[126]:
0.999999999999999
In [127]:
from operator import itemgetter
def draw feature importances(tree model, X dataset, figsize=(18,5)):
    Вывод важности признаков в виде графика
    # Сортировка значений важности признаков по убыванию
    list to sort = list(zip(X dataset.columns.values, tree model.feature importances ))
    sorted list = sorted(list to sort, key=itemgetter(1), reverse = True)
    # Названия признаков
    labels = [x for x,_ in sorted_list]
    # Важности признаков
   data = [x for _,x in sorted_list]
    # Вывод графика
    fig, ax = plt.subplots(figsize=figsize)
    ind = np.arange(len(labels))
   plt.bar(ind, data)
   plt.xticks(ind, labels, rotation='vertical')
    # Вывод значений
    for a,b in zip(ind, data):
        plt.text(a-0.05, b+0.01, str(round(b,3)))
    plt.show()
    return labels, data
In [128]:
```

('concavity error', 0.0), ('concave points error', 0.0),

```
breast tree cl fl, breast tree cl fd = draw feature importances(breast tree cl, breast x
```



oothness

perimeter concavity

st fractal

worst smoothr

dimension

compactness

area

orst

```
In [129]:
```

```
# Список признаков, отсортированный на основе важности, и значения важности breast_tree_cl_fd
```

```
Out[129]:
(['worst radius',
  'worst concave points',
  'worst texture',
  'worst area',
  'mean texture',
  'area error',
  'mean concavity',
  'worst smoothness',
  'worst symmetry',
  'mean smoothness',
  'fractal dimension error',
  'symmetry error',
  'compactness error',
  'worst concavity',
  'smoothness error',
  'mean radius',
  'mean perimeter',
  'mean area',
  'mean compactness',
  'mean concave points',
  'mean symmetry',
  'mean fractal dimension',
  'radius error',
  'texture error',
  'perimeter error',
  'concavity error',
  'concave points error',
  'worst perimeter',
  'worst compactness',
  'worst fractal dimension'],
 [0.6955935182252058,
 0.1389382501669036,
 0.07728413233375948,
 0.016724478603093007,
 0.011277152370382112,
 0.008936807857691388,
 0.008771118510297198,
 0.007387982534891388,
 0.007315997688141106,
 0.007016894808237761,
 0.00644408706878978,
 0.005831348020582203,
 0.005638576185191056,
 0.0018358155021552392,
 0.0010038401246787545,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0,
 0.0])
```

In [130]:

```
breast x ds sorted = breast x ds[breast tree cl fl]
breast x ds sorted.head()
Out[130]:
           worst
                                                                                                  mean
   worst
                  worst
                        worst
                               mean
                                      area
                                              mean
                                                         worst
                                                                  worst
                                                                            mean
                                                                                        mean
         concave
                                                                                                 fractal
   radius
                 texture
                              texture
                                      error
                                           concavity smoothness symmetry smoothness
                                                                                     symmetry
          points
                                                                                              dimension
   25.38
          0.2654
                  17.33 2019.0
                               10.38 153.40
                                             0.3001
                                                        0.1622
                                                                 0.4601
                                                                           0.11840
                                                                                        0.2419
                                                                                                0.07871
   24.99
          0.1860
                  23.41 1956.0
                               17.77
                                      74.08
                                             0.0869
                                                        0.1238
                                                                 0.2750
                                                                           0.08474 ...
                                                                                        0.1812
                                                                                                0.05667
2
   23.57
          0.2430
                  25.53 1709.0
                               21.25
                                      94.03
                                             0.1974
                                                        0.1444
                                                                 0.3613
                                                                           0.10960
                                                                                        0.2069
                                                                                                0.05999
   14.91
          0.2575
                  26.50
                               20.38
                                      27.23
                                             0.2414
                                                        0.2098
                                                                 0.6638
                                                                           0.14250 ...
                                                                                        0.2597
                                                                                                0.09744
                        567.7
          0.1625
                               14.34
                                             0.1980
                                                        0.1374
                                                                 0.2364
                                                                           0.10030 ...
                                                                                        0.1809
                                                                                                0.05883
   22.54
                  16.67 1575.0
                                      94.44
5 rows × 30 columns
                                                                                                    •
In [149]:
breast_X_train_2, breast_X_test_2, breast_y_train_2, breast_y_test_2 = train_test_split(
    breast_x_ds_sorted, breast.target, test_size=0.5, random_state=1)
breast_X_train_2.shape, breast X test 2.shape
Out[149]:
((284, 30), (285, 30))
In [150]:
# Обучим дерево и предскажем результаты на всех признаках
breast tree cl feat 1 = DecisionTreeClassifier(random state=1).fit(breast X train 2, bre
ast_y_train_2)
breast y test predict = breast tree cl feat 1.predict(breast X test 2)
breast y test predict.shape
Out[150]:
(285,)
In [151]:
# Проверим точность по классам
print accuracy score for classes (breast y test 2, breast y test predict)
        Accuracy
Метка
    0.8737864077669902
0
    0.9010989010989011
In [152]:
# Обучим дерево и предскажем результаты на единственном самом важном признаке
breast tree cl feat 2 = DecisionTreeClassifier(random state=1).fit(breast X train 2[[bre
ast_tree_cl_fl[0]]], breast_y_train_2)
breast y test predict 2 = breast tree cl feat 2.predict(breast X test 2[[breast tree cl f
breast_y_test_predict_2.shape
Out[152]:
(285,)
In [153]:
# Проверим точность по классам
print accuracy score for classes (breast y test 2, breast y test predict 2)
Метка
        Accuracy
```

Пересортируем признаки на основе важности

0.7766990291262136

1 U.OJJOU4JJJOU4JJJO

Качество моделей с помощью двух подходящих для задачи метрик. Сравнение качеств полученных моделей.

В качестве метрик для решения задачи классификации будем использовать:

Метрика precision: precision

$$=\frac{TP}{TP+FP}$$

Метрика recall (полнота): recall

In [207]:

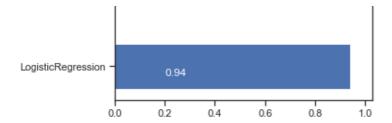
In [205]:

Метод опорных векторов (SVC)

$$=\frac{TP}{TP+FN}$$

```
def vis_models_quality(array_metric, array_labels, str_header, figsize=(5, 5)):
    fig, ax1 = plt.subplots(figsize=figsize)
    pos = np.arange(len(array_metric))
    rects = ax1.barh(pos, array metric,
                     align='center',
                     height=0.5,
                     tick label=array labels)
    ax1.set_title(str_header)
    for a,b in zip(pos, array_metric):
        plt.text(0.2, a-0.1, str(round(b,3)), color='white')
    plt.show()
In [200]:
# Логистическая регрессия (LogisticRegression)
precision_score(breast_y_test, pred_breast_y_test), recall_score(breast_y_test, pred_brea
st y test)
Out[200]:
(0.9144385026737968, 0.9395604395604396)
In [201]:
# Метод опорных векторов (SVC)
precision score(breast y test 1, breast y pred 1), recall score(breast y test 1, breast y
_pred_1)
Out[201]:
(0.89, 0.978021978021978)
In [203]:
# Деревья решений (DecisionTreeClassifier)
precision_score(breast_y_test_2, breast_y_test_predict_2), recall_score(breast_y_test_2,
breast y test predict 2)
Out[203]:
(0.8763440860215054, 0.8956043956043956)
In [199]:
# Логистическая регрессия
accuracy score (breast y test, pred breast y test)
Out[199]:
0.9052631578947369
```

```
accuracy_score(breast_y_test_1, breast_y_pred_1)
Out[205]:
0.9087719298245615
In [204]:
# Деревья решений (DecisionTreeClassifier)
accuracy_score(breast_y_test_2, breast_y_test_predict_2)
Out[204]:
0.8526315789473684
In [231]:
# Результаты
array labels = ['LogisticRegression','SVC', 'DecisionTreeClassifier']
array_mae = [precision_score(breast_y_test, pred_breast_y_test),
             precision_score(breast_y_test_1, breast_y_pred_1),
             precision score(breast y test 2, breast y test predict 2)]
In [232]:
# Визуализация результатов
vis models quality(array mae, array labels, 'precision score')
                           precision_score
 DecisionTreeClassifier
                      0.876
           SVC -
   LogisticRegression ·
              0.0
                                           0.8
In [233]:
# Результаты
array_labels = ['LogisticRegression','SVC', 'DecisionTreeClassifier']
array mae = [recall score(breast y test, pred breast y test),
              recall score (breast y test 1, breast y pred 1),
              recall score(breast y test 2, breast y test predict 2)]
In [234]:
# Визуализация результатов
vis models quality(array mae, array labels, 'recall score')
                             recall_score
 DecisionTreeClassifier
           SVC ·
                      0.978
```



In [235]:

In [236]:

```
# Визуализация результатов
vis_models_quality(array_mae, array_labels, 'accuracy_score')
```

